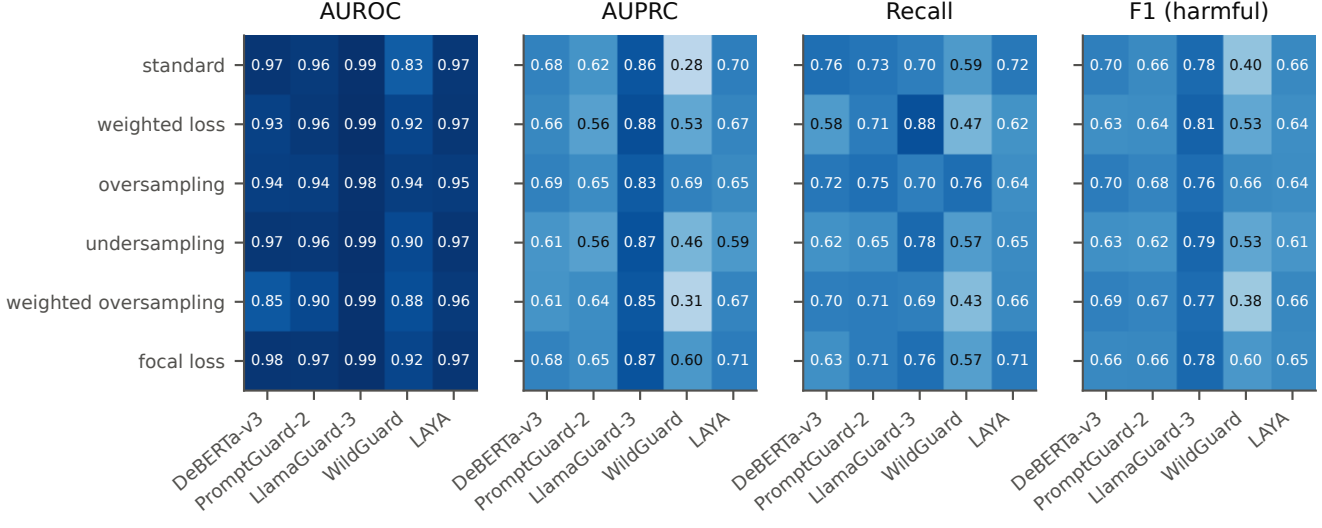
AUROC
AUPRC
Recall
F1 (harmful)
standard
weighted loss
oversampling
undersampling
weighted oversampling
focal loss
0.97 0.96 0.99 0.83 0.97
0.93 0.96 0.99 0.92 0.97
0.94 0.94 0.98 0.94 0.95
0.97 0.96 0.99 0.90 0.97
0.85 0.90 0.99 0.88 0.96
0.98 0.97 0.99 0.92 0.97
0.68 0.62 0.86 0.28 0.70
0.66 0.56 0.88 0.53 0.67
0.69 0.65 0.83 0.69 0.65
0.61 0.56 0.87 0.46 0.59
0.61 0.64 0.85 0.31 0.67
0.68 0.65 0.87 0.60 0.71
0.76 0.73 0.70 0.59 0.72
0.58 0.71 0.88 0.47 0.62
0.72 0.75 0.70 0.76 0.64
0.62 0.65 0.78 0.57 0.65
0.70 0.71 0.69 0.43 0.66
0.63 0.71 0.76 0.57 0.71
0.70 0.66 0.78 0.40 0.66
0.63 0.64 0.81 0.53 0.64
0.70 0.68 0.76 0.66 0.64
0.63 0.62 0.79 0.53 0.61
0.69 0.67 0.77 0.38 0.66
0.66 0.66 0.78 0.60 0.65
DeBERTa-v3
PromptGuard-2
LlamaGuard-3
WildGuard
LAYA